Wordcloud chart

1. Khái niệm

➢**Định nghĩa**: Wordcloud (biểu đồ đám mây từ) là một dạng biểu đồ trực quan hóa văn bản, thể hiện **tần suất xuất hiện** của các từ trong tập dữ liệu, với kích thước của từ tỉ lệ thuận với tần suất xuất hiện.



2. Cấu trúc

- **Từ (Words):** Các từ trong tập dữ liệu được sắp xếp ngẫu nhiên và kích thước tương ứng với tần suất xuất hiện.
- **Kích thước từ:** Từ xuất hiện càng nhiều, kích thước của nó càng lớn.
- **Màu sắc:** Có thể sử dụng nhiều màu sắc để làm nổi bật các từ quan trọng hoặc theo nhóm từ khóa.
- **Bố cục**: Thường là ngẫu nhiên hoặc theo các mẫu hình xác định trước (hình tròn, hình vuông, trái tim, v.v.).



3. Ưu điểm

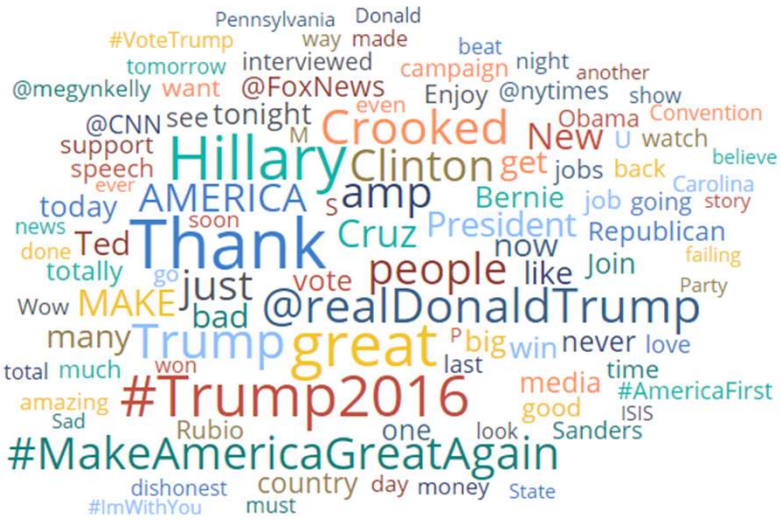
- **Trực quan và đơn giản**: Wordcloud giúp dễ dàng nhận biết các từ xuất hiện nhiều nhất trong văn bản.
- **Khám phá nhanh nội dung**: Cung cấp cái nhìn tổng quan về chủ đề hoặc xu hướng trong dữ liệu văn bản.
- **Phân tích tần suất từ ngữ**: Dùng để xác định các từ khóa chính, tiêu điểm trong bài viết hoặc bình luận của người dùng.
- **Phù hợp cho dữ liệu phi cấu trúc**: Tốt cho việc xử lý và phân tích văn bản từ các nguồn không có cấu trúc (bài báo, mạng xã hội, v.v.).

4. Nhược điểm

➢Không cung cấp bối cảnh của các từ (thiếu thông tin về mối quan hệ giữa các từ).

➢Dễ gây hiểu nhầm khi các từ đơn lẻ được làm nổi bật mà không có thông tin bổ sung.

➢Không phù hợp cho các dữ liệu có tính phức tạp cao hoặc cần phân tích sâu.



5. Các ứng dụng

➢**Phân tích phản hồi khách hàng**: Xem từ khóa nào xuất hiện nhiều trong phản hồi để hiểu rõ nhu cầu và vấn đề của khách hàng.

➢**Phân tích truyền thông xã hội**: Phân tích các từ khóa phổ biến trên Twitter, Facebook để khám phá xu hướng.

➢**Phân tích tài liệu**: Tóm tắt nội dung của các bài báo, bài viết, hay tài liệu nghiên cứu dựa trên các từ khóa quan trọng.

➢**Đánh giá thương hiệu** (Brand Sentiment Analysis): Hiểu nhận diện thương hiệu thông qua từ khóa được nhắc đến nhiều trên các kênh truyền thông.





5. Các ứng dụng

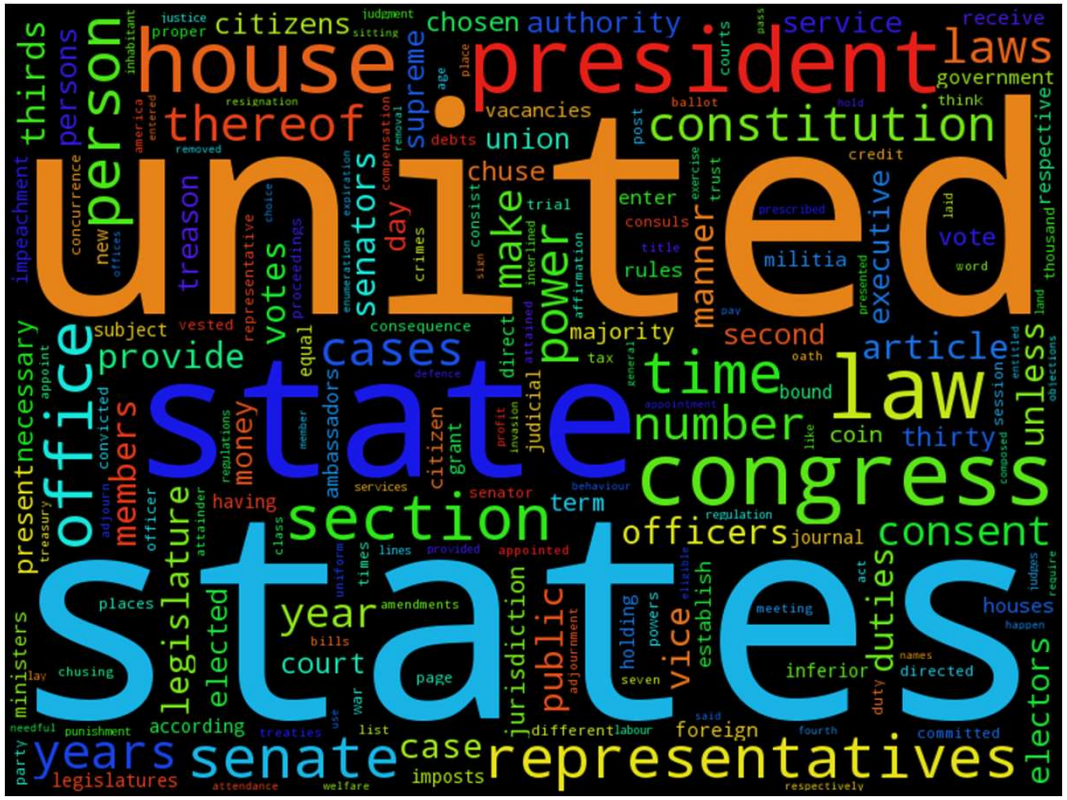




5. Các ứng dụng







6. Lưu ý khi sử dụng

- **Lựa chọn từ ngữ phù hợp:** Có thể tiền xử lý và loại bỏ các từ không mang nhiều giá trị hoặc các từ thông dụng.
- **Tập trung vào ngữ cảnh**: Wordcloud chỉ hiển thị tần suất từ, cần lưu ý đến ngữ cảnh và ý nghĩa mà các từ này mang lại.
- **Không lạm dụng**: Wordcloud có thể tạo hiệu ứng thị giác tốt nhưng không thay thế hoàn toàn các phân tích sâu và chi tiết hơn.
- **Cân nhắc về màu sắc và kích thước**: Đảm bảo rằng wordcloud có sự cân bằng, tránh gây rối mắt cho người xem.

7. Cách vẽ

1. **Chuẩn bị dữ liệu:**
    - Lấy dữ liệu văn bản từ các nguồn như bình luận, bài viết, email, báo cáo, v.v.
    - Làm sạch dữ liệu (loại bỏ các từ phổ biến không có giá trị như 'the', 'and', 'is',...)
2. **Chọn công cụ:**
    - Có thể sử dụng các công cụ phổ biến như Python (với thư viện `wordcloud`), R, hoặc các phần mềm trực quan hóa khác như Tableau, Power BI.
3. **Tùy chỉnh:**
    - Thiết lập kích thước từ, màu sắc, bố cục, và hình dạng cho wordcloud.
4. **Xuất và phân tích kết quả:**
    - Tạo biểu đồ và giải thích ý nghĩa của các từ khóa lớn nhất.

7. Cách vẽ

```python
import requests
from bs4 import BeautifulSoup
from wordcloud import WordCloud, STOPWORDS
import matplotlib.pyplot as plt

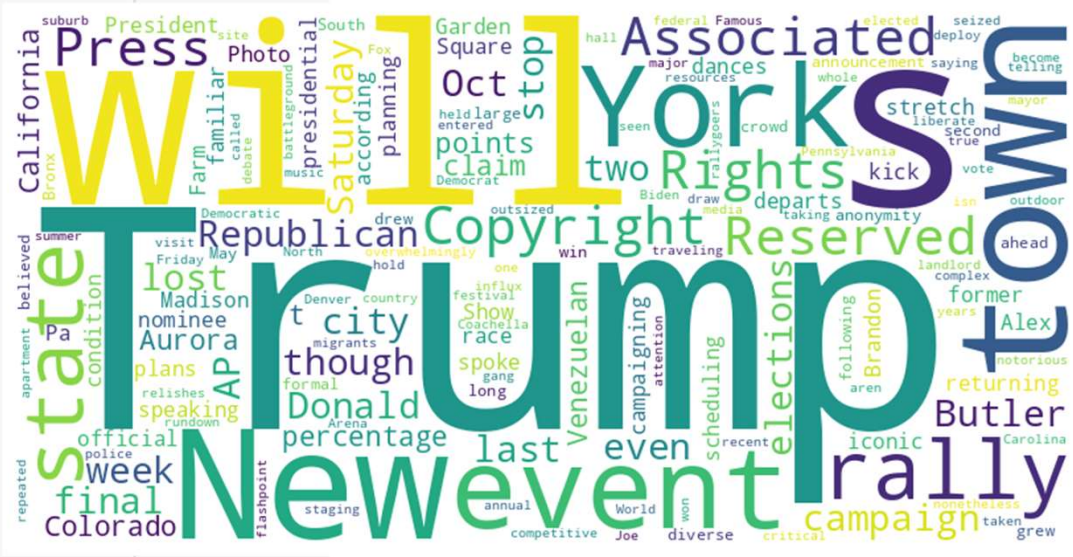
# Lấy nội dung bài báo, thay thế bằng URL bài báo bạn muốn
url = "https://apnews.com/article/trump-madison-square-garden-a65158306ebd021a6dc094d0ac3f680d"
response = requests.get(url)
soup = BeautifulSoup(response.content, "html.parser")

# Trích xuất văn bản từ bài báo, lấy nội dung từ thẻ <p> HTML
text = " ".join([p.get_text() for p in soup.find_all("p")])

# Loại bỏ stop words, thêm nếu cần
stopwords = set(STOPWORDS)
stopwords.update(["said", "would", "could", "told", "also"])

# Tạo wordcloud
wordcloud = WordCloud(width=800, height=400,
                      background_color="white",
                      stopwords=stopwords,
                      min_font_size=10).generate(text)

# Hiển thị wordcloud
plt.figure(figsize=(8, 8), facecolor=None)
plt.imshow(wordcloud)
plt.axis("off")
plt.tight_layout(pad=0)
plt.show()
```



7. Cách vẽ

➢ Có thể loại bỏ các từ ngữ hoặc chữ cái không phù hợp như http, website link, các kí tự đặc biệt, hoặc cũng có thể viết hàm để loại bỏ những từ ngữ quá dài hoặc quá ngắn.

```python
import re

stopwords = set(STOPWORDS)
stopwords.update(["said", "would", "could", "told", "also"])

# Loại bỏ link
text = re.sub(r"http\S+|www\S+|https\S+", "", text)
# Loại bỏ kí tự đặc biệt, chỉ giữ lại chữ cái và khoảng trắng
text = re.sub(r"[^a-zA-Z\s]", "", text)

wordcloud = WordCloud(width=800, height=400,
                      background_color="white",
                      stopwords=stopwords,
                      min_font_size=10).generate(text)

# Hiển thị wordcloud
plt.figure(figsize=(8, 8), facecolor=None)
plt.imshow(wordcloud)
plt.axis("off")
plt.tight_layout(pad=0)
plt.show()
```

```python
import re

stopwords = set(STOPWORDS)
stopwords.update(["said", "would", "could", "told", "also"])

# Loại bỏ link
text = re.sub(r"http\S+|www\S+|https\S+", "", text)
# Loại bỏ kí tự đặc biệt, chỉ giữ lại chữ cái và khoảng trắng
text = re.sub(r"[^a-zA-Z\s]", "", text)

wordcloud = WordCloud(width=800, height=400,
                      background_color="white",
                      stopwords=stopwords,
                      min_font_size=10).generate(text)

frequencies = wordcloud.words_
filtered_frequencies = {}
for word, frequency in frequencies.items():
    # Ví dụ: Chỉ lấy các từ có tần suất trên 0.1
    if frequency >= 0.1:
        filtered_frequencies[word] = frequency

    # Ví dụ: Chỉ lấy các từ có độ dài >= 3 và <= 10
    if len(word) >= 3 or len(word) <= 10:
        filtered_frequencies[word] = frequency

wordcloud.generate_from_frequencies(filtered_frequencies)


# Hiển thị wordcloud
plt.figure(figsize=(8, 8), facecolor=None)
plt.imshow(wordcloud)
plt.axis("off")
plt.tight_layout(pad=0)
plt.show()
```

7. Cách vẽ

```python
from PIL import Image
import numpy as np
from wordcloud import WordCloud, STOPWORDS
import matplotlib.pyplot as plt
import requests
from io import BytesIO

# Tải ảnh từ link dùng user-agent fake để tránh 403 status code.
headers = {
    'User-Agent': 'Mozilla/5.0 (Windows; U; Windows NT 5.1; en-US; rv:1.9.0.7) Gecko/2009021608 Firefox/3.0.7'
}
response = requests.get("https://w7.pngwing.com/pngs/570/1019/png-transparent-computer-icons-heart-filled-love-heart-black.png",
                        headers=headers)

# Chuyển đổi thành hình ảnh đen trắng
mask_image = Image.open(BytesIO(response.content)).convert("L")
mask = np.array(mask_image)

wordcloud = WordCloud(width=900, height=900,
                      background_color="white",
                      stopwords=stopwords,
                      min_font_size=10,
                      max_words=200,  # Giới hạn số lượng từ
                      contour_width=3,  # Độ dày viền
                      contour_color='red',  # Màu viền
                      mask=mask).generate(text)


plt.figure(facecolor=None)
plt.imshow(wordcloud)
plt.axis("off")
plt.tight_layout(pad=0)
plt.show()
```



8. Bài tập

1) Vẽ hình wordcloud và nhận xét về nội dung hình, dữ liệu có thể lấy ở bất kì một trang web nào ví dụ như

https://vietnamnet.vn/,

https://vnexpress.net/tin-tuc-24h

https://thanhnien.vn/

https://abcnews.go.com/

https://www.foxnews.com/

https://www.bleepingcomputer.com/tag/apt/

https://thehackernews.com/

Vẽ ít nhất 2 hình dạng khác của wordcloud, ví dụ hình trái tim, hình chai rượu, hình quả hồ lô (số 8).